

# Práctica 8: Modelo de urnas

1445183

26 de marzo de 2019

## 1. Objetivo

Paralelizar el código proporcionado [1] y medir el tiempo que se ahorra con la paralelización, observar si el ahorro es estadísticamente significativo para diferentes combinaciones de  $k$  y  $n$ , donde  $k$  es tamaño de cúmulo y  $n$  número de partículas.

## 2. Descripción

Para medir el tiempo se hace uso de `Sys.time()`, después se hacen vectores para los diferentes valores de  $k$  y  $n$  con 30 réplicas, recopilando los datos obtenidos en un `data.frame` llamado `resultado`:

```
1 resultado<-data.frame()
2 k <- 10000
3 n <- 1000000
4 #cumulo <- c(1000, 10000)
5 #particula <- c(1000000, 10000000, 100000000)
6 #for (k in cumulo) {
7 # for (n in particula) {
8   for (replicas in 1:30) {
9     inicial<- Sys.time()
10    originales <- rnorm(k)
11    cumulos <- originales - min(originales) + 1
12    cumulos <- round(n * cumulos / sum(cumulos))
13    assert(min(cumulos) > 0)
14    diferencia <- n - sum(cumulos)
15    if (diferencia > 0) {
16      for (i in 1:diferencia) {
17        p <- sample(1:k, 1)
18        cumulos[p] <- cumulos[p] + 1
19      }
20    } else if (diferencia < 0) {
21      for (i in 1:-diferencia) {
22        p <- sample(1:k, 1)
23        if (cumulos[p] > 1) {
24          cumulos[p] <- cumulos[p] - 1
25        }
26      }
27    }
28  }
29 }
```

Para la prueba estadística se hace uso de `qqplot` para normalizar los valores.

### 3. Resultados

Se puede ver en la figura 1 la diferencia de tiempo usando los valores dados por la práctica de  $k$  y  $n$  siendo el código paralelizado el que presenta menor tiempo de compilación.




Figura 1: comparación de tiempos

En la figura 2 se puede observar que el tiempo es menor cuando se tiene una relación de  $k$  y  $n$  con los valores más bajos, las combinaciones de  $k$  y  $n$  se proporcionan en el cuadro 1.

Cuadro 1: Combinaciones de  $k$  y  $n$

Combinación	$k$	$n$
1	1000	1000000
2	1000	10000000
3	1000	100000000
4	10000	1000000
5	10000	10000000
6	10000	100000000

En la figura 3 se observa la normalización del experimento paralelizado, cúmulos ( $k$ ) de 1000 y 10000 con las 3 combinaciones de  $n$  correspondientes. Donde la relación de  $k$  y  $n$  con valores mayores dan una mejor normalización.







Figura 2: tiempo vs combinaciones de  $k$  y  $n$



(a) Paralelizado



(b)  $k$  de 1000 con los 3 valores de  $n$



(c)  $k$  de 10000 con los 3 valores de  $n$

Figura 3: Normalización de resultados

## 4. Conclusiones

Al tener una relación con valores de  $k$  y  $n$  pequeños el tiempo es menor pero los valores no son muy significativos, no se normalizan, y al tener una relación de  $k$  y  $n$  con valores grandes mejora la normalización pero el tiempo es mayor. Si se paraleliza el código aún más, se podrían obtener mejores tiempos al igual que un resultado más significativo.

## 5. Descripción

Para el *reto 1* se necesita saber en cuál paso los cúmulos son suficientemente grandes, usando los valores para  $k$  y  $n$  proporcionados por el código de la práctica [1] se obtienen los valores máximos de los cúmulos usando `max(cumulos)` y por medio de los histogramas se observan los pasos, se hacen 30 réplicas y se obtienen los datos estadísticos con `qqplot`.

## 6. Resultados

En la figura 4 se observan los valores máximos de cúmulos normalizados y en la figura 5 se puede observar que en el paso 3 hay mayor cantidad de cúmulos grandes que ya pueden filtrarse.




Figura 4: normalización de valores máximos de cúmulos

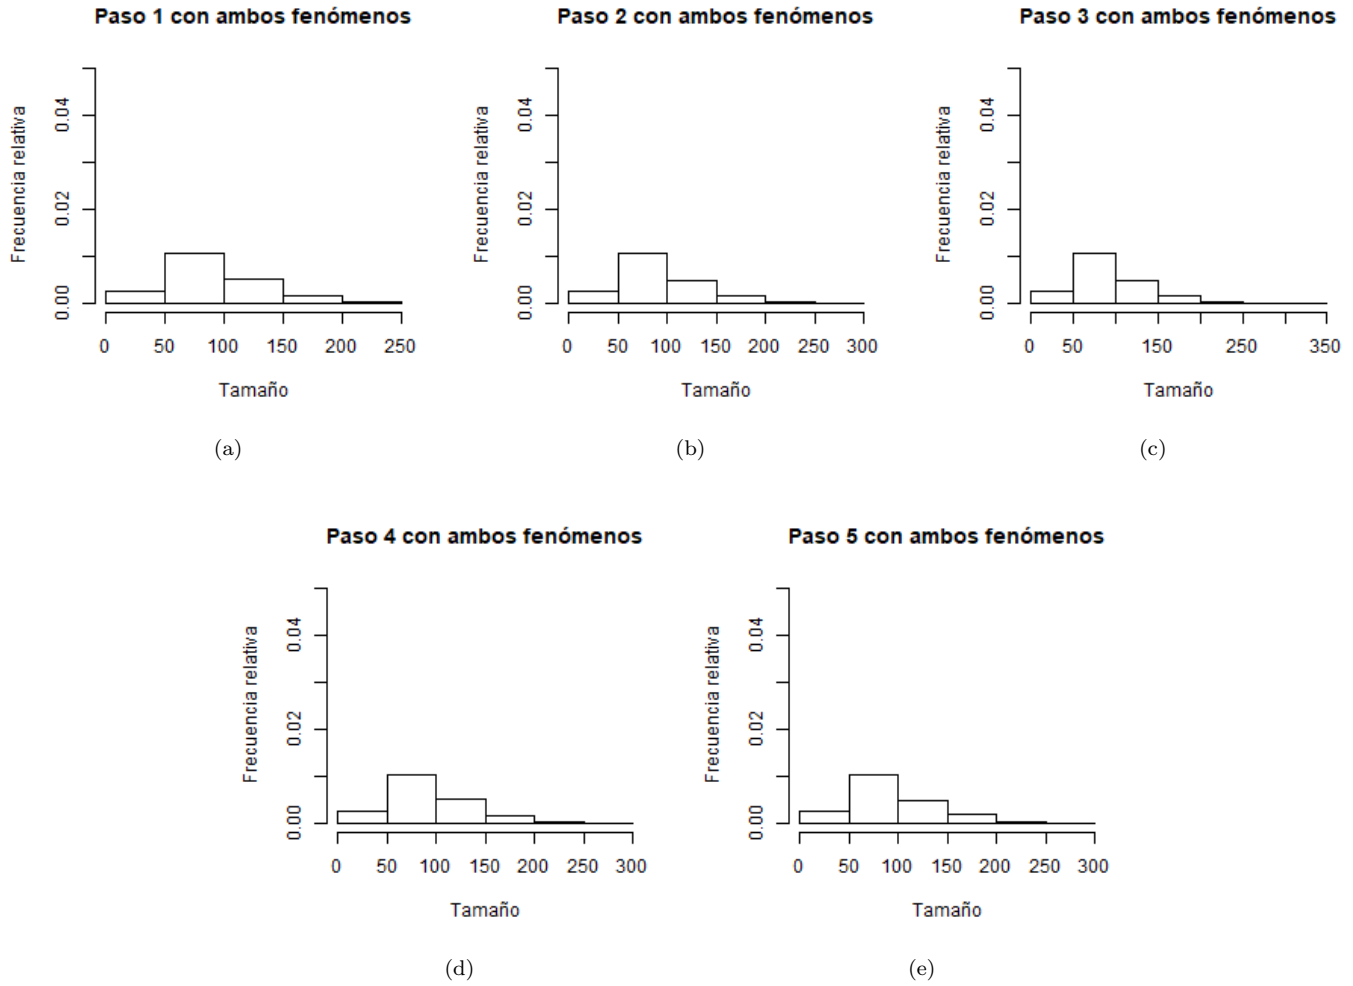


Figura 5: Histograma de pasos  
(frecuencia vs tamaño de cúmulos)

Reto 2

## 7. Descripción

Para determinar la importancia del valor de  $c$  (valor crítico), en el código modificado para el *Reto 1* se cambia su valor original dándole un valor de 40 y se grafica en una curva sigmoïdal.

## 8. Resultados

En la figura 6 se observa que al darle a  $c$  un valor de 40, la probabilidad de que se formen cúmulos que ya no se rompan. En la figura 7 se confirma en crecimiento de cúmulos a mayor cantidad de pasos.




Figura 6: Curva sigmoideal

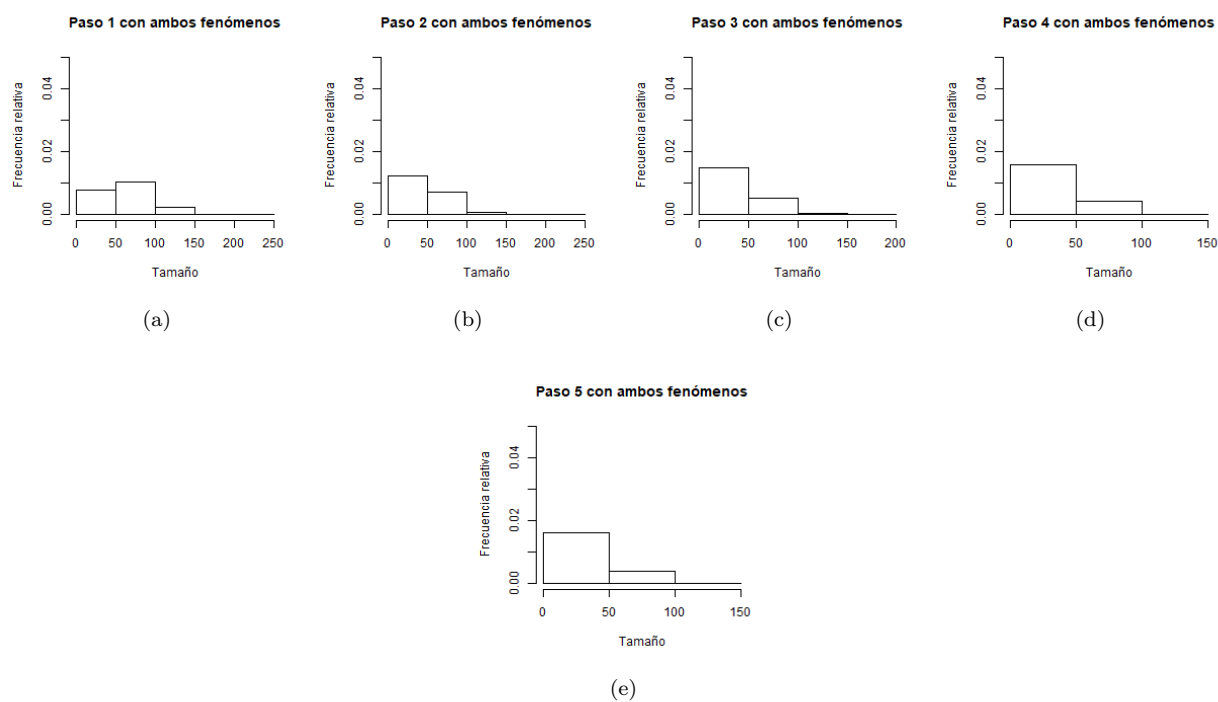


Figura 7: Histograma de pasos  
(frecuencia vs tamaño de cúmulos)

## 9. Conclusiones

El valor de  $c$  afecta en la probabilidad de que los cúmulos se rompan o no, esto afecta en cuál paso se tendrán cúmulos de tamaño grande para poder filtrarlos y por lo tanto los tiempos varían también, por ejemplo, en este caso de  $c=40$ , hay mayor probabilidad de que los cúmulos no se rompan, por lo que disminuirá el tiempo ya que no se tendrán que unir cúmulos rotos y se podrán filtrar más rápido.

## Referencias

- [1] Elisa Schaeffer. Práctica 8: modelo de urnas, 2019. URL <https://elisa.dyndns-web.com/teaching/comp/par/p8.html>.